

## 주성분 분석 (Principal Component Analysis)

# 주성분 분석 강의 자료 개요

---

- 주성분 분석 개요
- 주성분 분석 수리적 배경
- 주성분 분석 알고리즘
- 주성분 분석 예제


# 다변량 데이터

변수 관측치	$X_1$	...	$X_i$	...	$X_p$
$N_1$	$x_{11}$	...	$x_{1i}$	...	$x_{1p}$
...	...	...	...	...	...
$N_i$	$x_{i1}$	...	$x_{ii}$	...	$x_{ip}$
...	...	...	...	...	...
$N_n$	$x_{n1}$	...	$x_{ni}$	...	$x_{np}$

- 관측치: 샘플 (제품, 고객, 환자, ...)
- 변수: 각 관측치의 특성치
- 다변량 데이터: 변수가 2개 이상 존재하는 데이터

# 변수선택/추출을 통한 차원 축소

- 변수선택: 분석 목적에 부합하는 소수의 예측변수만을 선택
  - 장점: 선택한 변수 해석 용이
  - 단점: 변수간 상관관계 고려 어려움
- 변수추출: 예측변수의 변환(결합)을 통해 새로운 변수 추출
  - 장점: 변수간 상관관계 고려, 일반적으로 변수의 개수를 많이 줄일 수 있음
  - 단점: 추출된 변수의 해석이 어려움



# 변수선택/추출을 통한 차원 축소

---

- Supervised feature selection: Information gain, Stepwise regression, LASSO, Genetic algorithm, *many more...*
- Supervised feature extraction: Partial least squares (PLS)
- Unsupervised feature selection: PCA loading
- Unsupervised feature extraction: Principal component analysis (PCA), Wavelets transforms, Autoencoder

# PCA...

---

- Supervised feature selection: Information gain, Stepwise regression, LASSO, Genetic algorithm, *many more...*
- Supervised feature extraction: Partial least squares (PLS)
- Unsupervised feature selection: PCA loading
- **Unsupervised feature extraction: Principal component analysis (PCA)**, Wavelets transforms, Autoencoder



Principal Components Analysis






Principle Components Analysis



# PCA 개요

- 고차원 데이터를 효과적으로 분석하기 위한 대표적 분석 기법
- 차원축소, 시각화, 군집화, 압축






# PCA 개요

- PCA는  $n$  개의 관측치와  $p$  개의 변수로 구성된 데이터를 상관관계가 없는  $k$  개의 변수로 구성된 데이터 ( $n$  개의 관측치)로 요약하는 방식으로, 이 때 요약된 변수는 기존 변수의 선형조합으로 생성됨
- 원래 데이터의 분산을 최대한 보존하는 새로운 축을 찾고, 그 축에 데이터를 사영 (Projection) 시키는 기법
- 주요 목적
  - 데이터 차원 축소 ( $n \text{ by } p \rightarrow n \text{ by } k, \text{ where } k \ll p$ )
  - 데이터 시각화 및 해석
- 일반적으로 PCA는 전체 분석 과정 중 초기에 사용


# PCA 개요




$Z_1, Z_2$ , 그리고  $Z_3$  는 기존 변수인  $X_1, X_2, \dots, X_p$  의 선형 조합으로 새롭게 생성된 변수

# PCA 개요


## Reduce data from 3D to 2D or 1D



3D data



2D reduction



1D reduction

# PCA 개요

$Z$  is a linear combination (선형결합) of the original  $p$  variables in  $X$

$$Z_1 = \alpha_{11}X_1 + \alpha_{12}X_2 + \cdots + \alpha_{1p}X_p$$

$$Z_2 = \alpha_{21}X_1 + \alpha_{22}X_2 + \cdots + \alpha_{2p}X_p$$

$$\vdots$$
$$\vdots$$

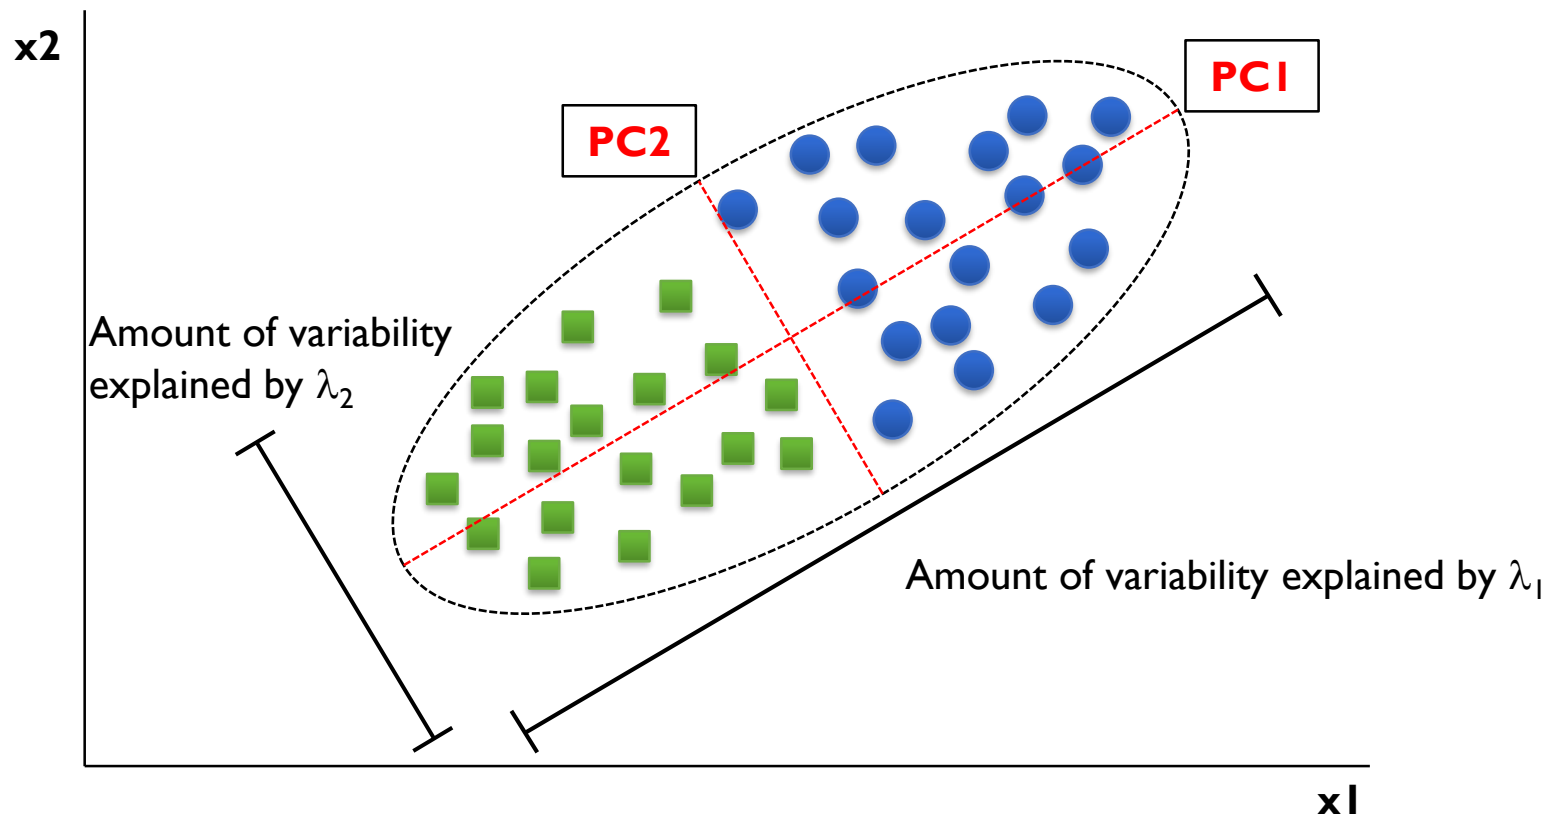
$$Z_p = \alpha_{p1}X_1 + \alpha_{p2}X_2 + \cdots + \alpha_{pp}X_p$$

- $X_1, X_2, \dots, X_p$ : 원래 변수 (original variable)
- $\mathbf{a}_i = [a_{i1}, a_{i2}, \dots, a_{ip}]$ :  $i$ 번째 기저(basis) 또는 계수 (Loading)
- $Z_1, Z_2, \dots, Z_p$ : 각 기저로 사영된 변환 후 변수 (주성분, Score)

# PCA 개요

- 주성분 분석


- 주성분분석을 통해 새로운 축(변수) 결정
- 주성분분석을 통해 새로운 기저에 사영된 데이터의 분산이 어느 정도인지 계산 가능



# PCA 개요

## ❖ 주성분 분석


- 아래 2차원 데이터를 좌측과 우측 두 개의 축에 사영시킬 경우 우측 기저 (basis)가 좌측 기저에 비해 손실되는 정보의 양(분산의 크기)이 적으므로 상대적으로 선호되는 기저라고 할 수 있음



# PCA 개요


## Principal Component Analysis

Find the new axis that  
**maximizes** the variance of data



## Minimum Variance Analysis

Find the new axis that  
**minimizes** the variance of data



# PCA 수리적 배경

변수 관측치	$X_1$	...	$X_i$	...	$X_p$
$N_1$	$x_{11}$	...	$x_{1i}$	...	$x_{1p}$
...	...	...	...	...	...
$N_i$	$x_{i1}$	...	$x_{ii}$	...	$x_{ip}$
...	...	...	...	...	...
$N_n$	$x_{n1}$	...	$x_{ni}$	...	$x_{np}$

$$\bar{X} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \dots \\ \bar{x}_p \end{bmatrix} \quad C_n = \begin{bmatrix} s_{11} & \dots & s_{1p} \\ \vdots & \ddots & \vdots \\ s_{p1} & \dots & s_{pp} \end{bmatrix} \quad R = \begin{bmatrix} 1 & r_{12} & \dots & r_{1p} \\ r_{21} & 1 & \dots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \dots & 1 \end{bmatrix}$$



# PCA 수리적 배경

- 공분산(Covariance)의 성질

- $\mathbf{X}$ 를 p개의 변수와 n개의 개체로 구성된 n by p 행렬로 정의할 때  $\mathbf{X}$ 의 공분산 행렬은 다음과 같음

$$\text{Cov}(\mathbf{X}) = \frac{1}{n} (\mathbf{X} - \bar{\mathbf{X}})(\mathbf{X} - \bar{\mathbf{X}})^T$$

- 공분산 행렬의 대각 성분은 각 변수의 분산과 같으며, 비대각행렬은 대응하는 두 변수의 공분산과 같음 (변수 개수: p)

$$\begin{aligned} C_x = \text{Var}[x] &= \begin{bmatrix} \text{Var}[x_1] & \text{Cov}[x_1, x_2] & \dots & \text{Cov}[x_1, x_p] \\ \text{Cov}[x_2, x_1] & \text{Var}[x_2] & \dots & \text{Cov}[x_2, x_p] \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}[x_p, x_1] & \text{Cov}[x_p, x_2] & \dots & \text{Var}[x_p] \end{bmatrix} \\ &= \begin{bmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \dots & \sigma_{pp} \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \dots & \sigma_p^2 \end{bmatrix} \end{aligned}$$


- 데이터의 총분산은 공분산행렬의 대각성분들의 합으로 표현됨

$$\text{tr}[\text{Cov}(\mathbf{X})] = \text{Cov}(\mathbf{X})_{11} + \text{Cov}(\mathbf{X})_{22} + \text{Cov}(\mathbf{X})_{33} + \dots + \text{Cov}(\mathbf{X})_{pp}$$

# PCA 수리적 배경

- 사영 (Projection)

- 한 벡터  $\vec{b}$ 를 다른 벡터  $\vec{a}$ 에 사영시킨다는 것은 벡터  $\vec{b}$ 로부터 벡터  $\vec{a}$ 에 수직인 점까지의 길이를 가지며 벡터  $\vec{a}$ 와 같은 방향을 갖는 벡터를 찾는다는 것을 의미



$$(\vec{b} - p\vec{a})^T \vec{a} = 0 \Rightarrow \vec{b}^T \vec{a} - p\vec{a}^T \vec{a} = 0 \Rightarrow p = \frac{\vec{b}^T \vec{a}}{\vec{a}^T \vec{a}}$$

$$\vec{x} = p\vec{a} = \frac{\vec{b}^T \vec{a}}{\vec{a}^T \vec{a}} \vec{a}$$

If  $\vec{a}$  is unit vector

$$p = \vec{b}^T \vec{a} \Rightarrow \vec{x} = p\vec{a} = (\vec{b}^T \vec{a})\vec{a}$$


# PCA 수리적 배경

- 고유값 및 고유벡터

- 어떤 행렬  $\mathbf{A}$ 에 대해 상수  $\lambda$ 와 벡터  $\mathbf{x}$ 가 다음 식을 만족할 때,  $\lambda$ 와  $\mathbf{x}$ 를 각각 행렬  $\mathbf{A}$ 의 고유값(eigenvalue) 및 고유벡터(eigenvector)라고 함

$$\mathbf{Ax} = \lambda\mathbf{x} \quad \rightarrow \quad (\mathbf{A} - \lambda\mathbf{I})\mathbf{x} = 0$$


- 벡터에 행렬을 곱한다는 것은 해당 벡터를 선형변환(linear transformation)한다는 의미  $\rightarrow$  고유벡터는 이 변환에 의해 방향이 변하지 않는 벡터를 의미



# Recall PCA 개요


## Principal Component Analysis

Find the new axis that  
**maximizes** the variance of data



## Minimum Variance Analysis

Find the new axis that  
**minimizes** the variance of data



# PCA 알고리즘 – 주성분 추출

- Assume that we have the centered data (i.e.,  $\bar{X}_i = 0$ ,  $i = 1, \dots, p$ )
- Let  $\mathbf{X}$  be an  $p$ -dimensional random vector with the covariance matrix  $\Sigma$
- Let  $\alpha$  be an  $p$ -dimensional vector of length one (i.e.,  $\alpha^T \alpha = 1$ )
- Let  $\mathbf{Z} = \alpha^T \mathbf{X}$  be the projection of  $\mathbf{X}$  onto the direction  $\alpha$

**The main purpose in PCA is**

**to find  $\alpha$  that produces the largest variance of  $\mathbf{Z}$**

$$\text{Max Var}(\mathbf{Z}) = \text{Var}(\alpha^T \mathbf{X}) = \alpha^T \text{Var}(\mathbf{X}) \alpha = \alpha^T \Sigma \alpha$$

$$\text{s.t. } \|\alpha\| = \alpha^T \alpha = 1$$

# PCA 알고리즘 - 주성분 추출

$$\text{Max } \alpha^\top \Sigma \alpha = \alpha^\top E \Lambda E^\top \alpha$$

$$\text{s.t. } \|\alpha\|=1$$

$$\text{Max } \beta^\top \Lambda \beta \text{ where } \beta = E^\top \alpha$$

$$\text{s.t. } \|\beta\|=1$$

eigenvalues and eigenvector of  $\Sigma$

$$[E \ \Lambda] = \text{svd}(\Sigma)$$

$$\lambda_1 \geq \dots \geq \lambda_m \geq 0$$

$$e_1, \dots, e_m$$

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$$

$$\text{Max } \lambda_1 \beta_1^2 + \lambda_2 \beta_2^2 + \dots + \lambda_m \beta_m^2$$

$$\text{s.t. } \beta_1^2 + \beta_2^2 + \dots + \beta_m^2 = 1$$

$$\lambda_1 > \lambda_2 > \dots > \lambda_m$$

Thus, the optimal value is  $\lambda_1$  and  $\alpha=e_1$

# PCA - 예제

**X** =

$X_1$	$X_2$	$X_3$
0.2	5.6	3.56
0.45	5.89	2.4
0.33	6.37	1.95
0.54	7.9	1.32
0.77	7.87	0.98

**X** =

$X_1$	$X_2$	$X_3$
-1.1930	-1.0300	1.5012
-0.0370	-0.7647	0.3540
-0.5919	-0.3257	-0.0910
0.3792	1.0739	-0.7140
1.4427	1.0464	-1.0502

(normalize X to  
 $E(X_i)=0$ ,  
 $Var(X_i)=1$ )

Covariance(**X**) =

0.0468	0.1990	-0.1993
0.1990	1.1951	-1.0096
-0.1993	-1.0096	1.0225

Correlation(**X**) =

1	0.8417	-0.8840
0.8417	1	-0.9133
-0.8840	-0.9133	1

Question)  $\text{Corr}(X_1, X_2) =$

$\text{Corr}(X_3, X_3) =$

# PCA - 예제



## ❖ 데이터 정규화

- 모든 변수의 평균을 0으로 맞춤

$x_1$	2.5	0.5	2.2	1.9	3.1	2.3	2	1	1.5	1.1
$x_2$	2.4	0.7	2.9	2.2	3	2.7	1.6	1.1	1.6	0.9

$x_1$	0.69	-1.31	0.39	0.09	1.29	0.49	0.19	-0.81	-0.31	-0.71
$x_2$	0.49	-1.21	0.99	0.29	1.09	0.79	-0.31	-0.81	-0.31	-1.01





# PCA - 예제

---

The Eigenvalue-Eigenvector pairs on the correlation matrix,  $\Sigma$

$$[E \ \Lambda \ V] = \text{svd}(\Sigma)$$

$$\lambda_1 = 0.0786, \quad e_1^T = [0.2590 \quad 0.5502 \quad 0.7938]$$

$$\lambda_2 = 0.1618, \quad e_2^T = [0.7798 \quad -0.6041 \quad 0.1643]$$

$$\lambda_3 = 2.7596, \quad e_3^T = [0.5699 \quad 0.5765 \quad -0.5855]$$

# PCA - 예제

$$\begin{aligned}\lambda_1 &= 0.0786, e_1^T = [0.2590 \quad 0.5502 \quad 0.7938] \\ \lambda_2 &= 0.1618, e_2^T = [0.7798 \quad -0.6041 \quad 0.1643] \\ \lambda_3 &= 2.7596, e_3^T = [0.5699 \quad 0.5765 \quad -0.5855]\end{aligned}$$

,  $\mathbf{X} =$

$X_1$	$X_2$	$X_3$
-1.1930	-1.0300	1.5012
-0.0370	-0.7647	0.3540
-0.5919	-0.3257	-0.0910
0.3792	1.0739	-0.7140
1.4427	1.0464	-1.0502

(normalize  $\mathbf{X}$  to  
 $E(X_i)=0$ ,  
 $\text{Var}(X_i)=1$ )

$$\lambda_3 > \lambda_2 > \lambda_1$$

$$PC_1 = e_1^T X = 0.5699 \cdot X_1 + 0.5765 \cdot X_2 - 0.5855 \cdot X_3 = 0.5699 \cdot \begin{bmatrix} -1.1930 \\ -0.0370 \\ -0.5919 \\ 0.3792 \\ 1.4427 \end{bmatrix} + 0.5765 \cdot \begin{bmatrix} -1.0300 \\ -0.7647 \\ -0.3257 \\ 1.0739 \\ 1.0464 \end{bmatrix} - 0.5855 \cdot \begin{bmatrix} 1.5012 \\ 0.3540 \\ -0.0910 \\ -0.7140 \\ -1.0502 \end{bmatrix} = \begin{bmatrix} -2.1527 \\ -0.6692 \\ -0.4718 \\ 1.2533 \\ 2.0404 \end{bmatrix}$$

$$PC_2 = e_2^T X = \begin{bmatrix} -0.0615 \\ 0.4912 \\ -0.2798 \\ -0.4703 \\ 0.3204 \end{bmatrix}$$

$$PC_3 = e_3^T X = \begin{bmatrix} 0.3160 \\ -0.1493 \\ -0.4047 \\ 0.1223 \\ 0.1157 \end{bmatrix}$$

$$\therefore PC = \begin{bmatrix} -2.1527 & -0.0615 & 0.3160 \\ -0.6692 & 0.4912 & -0.1493 \\ -0.4718 & -0.2798 & -0.4047 \\ 1.2533 & -0.4703 & 0.1223 \\ 2.0404 & 0.3204 & 0.1157 \end{bmatrix}$$

# PCA - 예제

$$\text{Cov}(PC) = \begin{bmatrix} 2.7596 & 0 & 0 \\ 0 & 0.1618 & 0 \\ 0 & 0 & 0.0786 \end{bmatrix}$$

Question) Cov (PC1, PC2) =

Cov (PC2, PC3) =

Cov (PC3, PC1) =

Cov (PC1, PC1) =

주성분( PC)들은 서로 독립!

# PCA - 예제

The eigenvalues of  $\lambda_1, \lambda_2, \lambda_3$  are the variances of each principal component.

Based on the correlation matrix

$$\text{Var (PC1)} = 2.7596 = \lambda_3 \text{ (Largest eigenvalue)}$$


$$\text{Var (PC2)} = 0.1618 = \lambda_2$$

$$\text{Var (PC3)} = 0.0786 = \lambda_1$$

Proportion of total population variance due to the 1<sup>st</sup> principal component


$$= \frac{\lambda_3}{\lambda_1 + \lambda_2 + \lambda_3} = \frac{2.7596}{0.0786 + 0.1618 + 2.7596} = 0.920$$

# PCA – 예제 (몇 개의 주성분?)




- **선택 방식 1:** 고유값 감소율이 유의미하게 낮아지는 Elbow Point에 해당하는 주성분 수를 선택
- **선택 방식 2:** 일정 수준 이상의 분산비를 보존하는 최소의 주성분을 선택 (보통 70% 이상)

# PCA Score Plot - 예제




3D PCA score plot



3D plot from original data

# PCA Loading Plot - 예제

PCA Loading: 실제 변수가 주성분 결정에 얼마나 많은 영향을 미쳤는지



# PCA 알고리즘 - 요약

**Step 1.** 데이터 정규화 (mean centering)

**Step 2.** 기존 변수의 covariance (correlation) matrix 계산

**Step 3.** Covariance (correlation) matrix로부터 eigenvalue 및 이에 해당하는 eigenvector를 계산

**Step 4.** Eigenvalue 및 해당하는 eigenvectors 를 순서대로 나열

$$\lambda(1) > \lambda(2) > \lambda(3) > \lambda(4) > \lambda(5)$$

$$e(1) > e(2) > e(3) > e(4) > e(5), e(i), i=1, \dots, 5 \text{ is a vector}$$

**Step 5.** 정렬된 eigenvector를 토대로 기존 변수를 변환

$$PC1 = e(1)\mathbf{X} = e_{11} \cdot X_1 + e_{12} \cdot X_2 + \dots + e_{15} \cdot X_5$$

$$PC2 = e(2)\mathbf{X} = e_{21} \cdot X_1 + e_{22} \cdot X_2 + \dots + e_{25} \cdot X_5$$

$$\dots = \dots$$

$$PC5 = e(5)\mathbf{X} = e_{51} \cdot X_1 + e_{52} \cdot X_2 + \dots + e_{55} \cdot X_5$$



# PCA 한계


- 주성분 분석의 특징
  - 공분산 행렬의 고유벡터를 사용하므로 단일 가우시안(unimodal) 분포로 추정할 수 있는 데이터에 대해 서로 독립적인 축을 찾는데 사용할 수 있음
- 한계점 I
  - 데이터의 분포가 가우시안이 아니거나 다중 가우시안 (multimodal) 자료들에 대해서는 적용하기가 어려움
  - 대안: 커널 PCA, LLE (Locally Linear Embedding)



# PCA 한계



- 한계점 2

- 분류/예측 문제에 대해서 데이터의 범주 정보를 고려하지 않기 때문에 범주간 구분이 잘 되도록 변환을 해주는 것은 아님
  - 주성분분석은 단순히 변환된 축이 최대 분산방향과 정렬되도록 좌표회전을 수행함
  - 대안: Partial Least Square (PLS)




# PCA – 실제 예제

약 13,000개의  
28 x 28 픽셀 이미지




1? 7?



# PCA – 실제 예제

- **IRIS** 데이터에 대한 주성분분석
  - IRIS 데이터: 150개의 IRIS에 대해 4개 입력변수, 1개 출력변수 (3 클래스)


<https://archive.ics.uci.edu/ml/datasets/iris>



Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
5.1	3.5	1.4	0.2	1
4.9	3	1.4	0.2	1
4.7	3.2	1.3	0.2	1
4.6	3.1	1.5	0.2	1
5	3.6	1.4	0.2	1
5.4	3.9	1.7	0.4	1
...	...	...	...	...

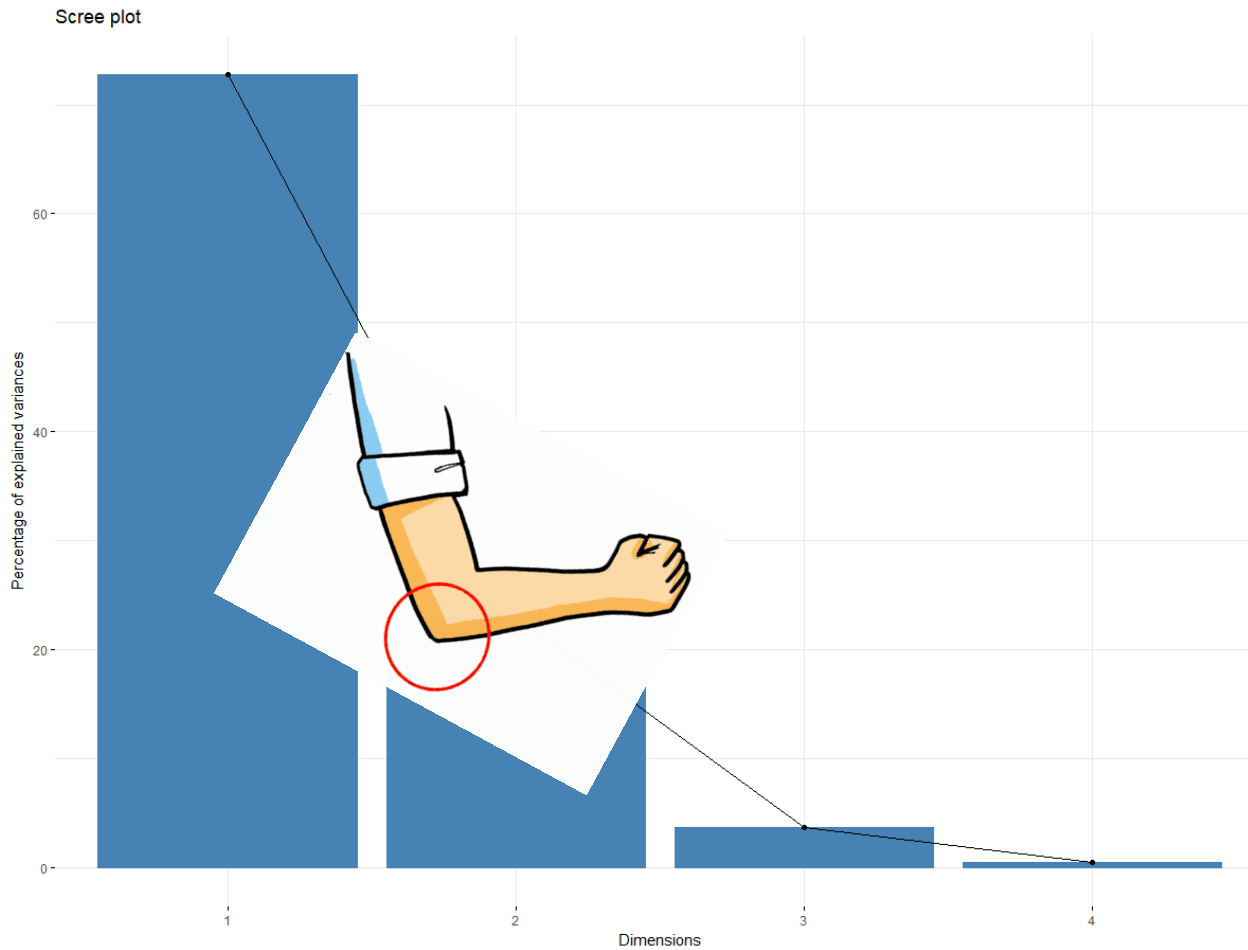
# PCA – Matrix Plot

- 입력변수들이 대체로 강한 양의 상관관계를 보이고 있음




# PCA – Scree Plot

- 1-2개의 주성분 (PC)로 충분



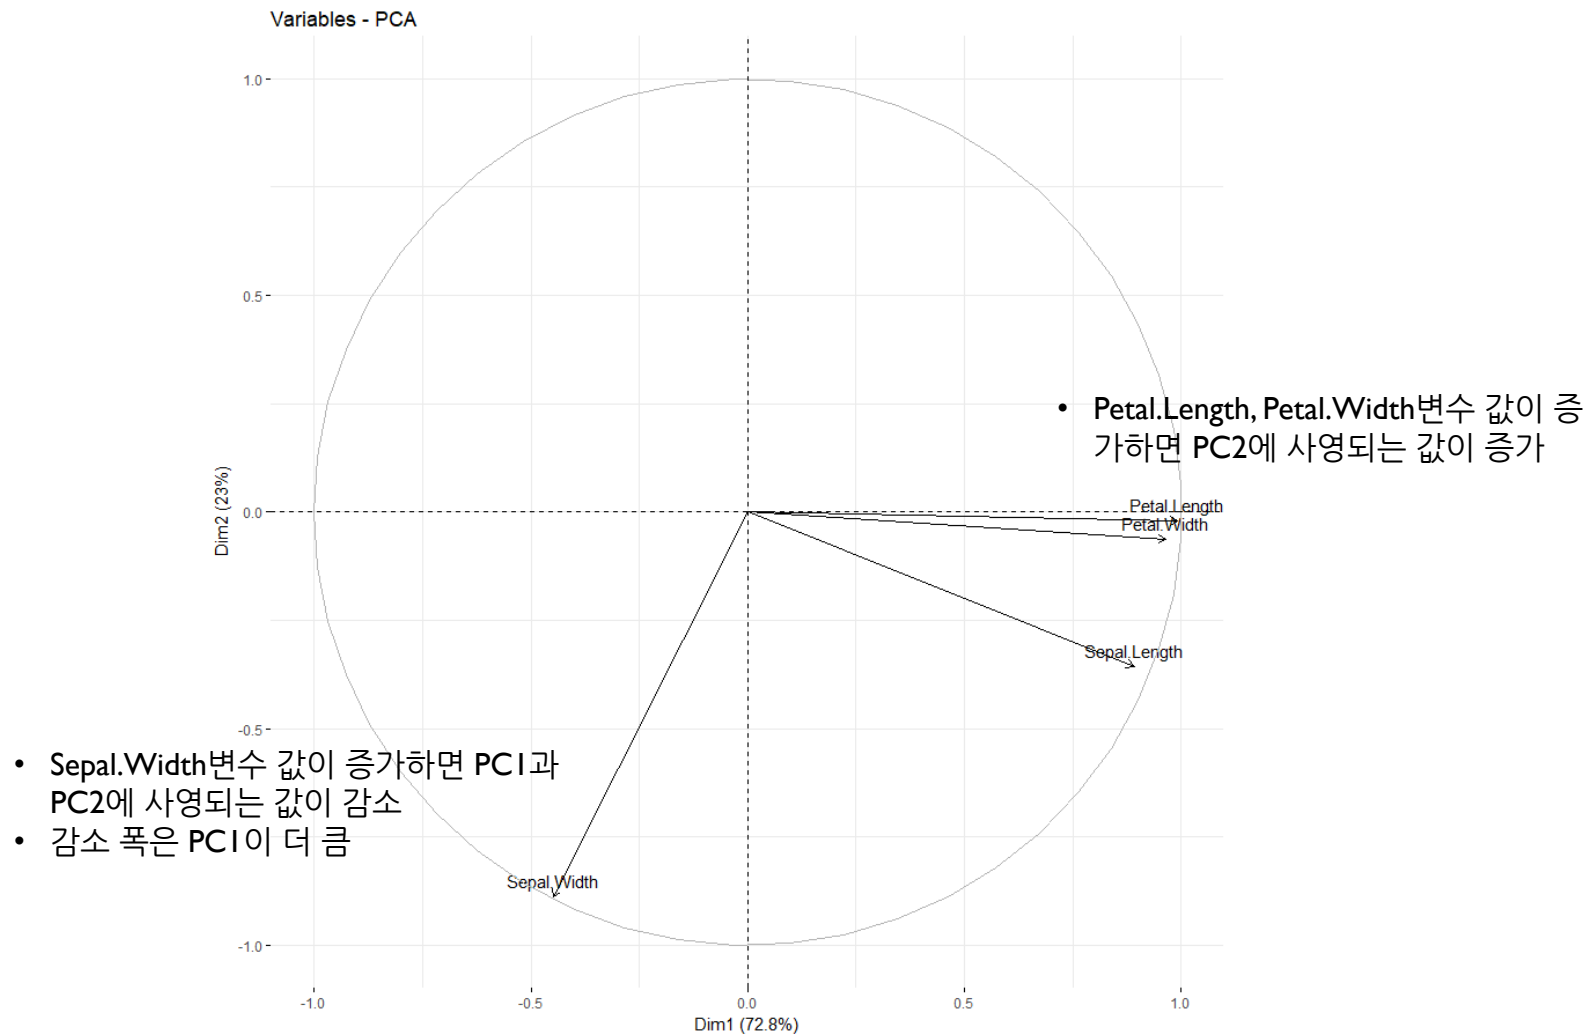
# PCA – 2D Score Plot

- PCA의 핵심 그래프
- 같은 품종의 IRIS 가 같은 그룹에 포함



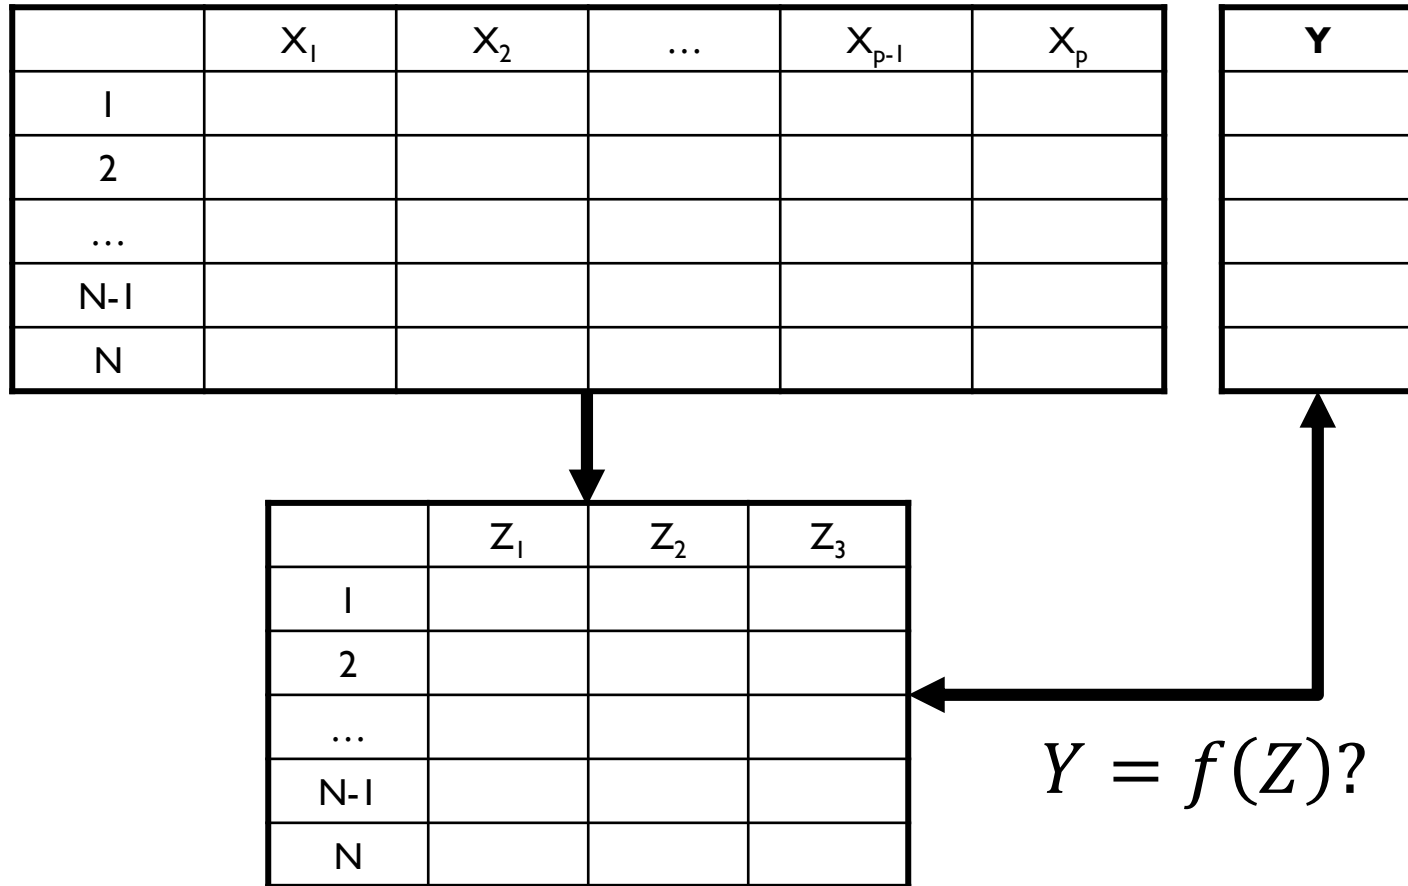
# PCA – Loading Plot

- 주요 입력변수 파악





# PCA 응용 - Principal Component Regression (PCR)



# PCA 응용 - Principal Component Regression (PCR)

---

- PCR은 PCA를 통해 생성한  $k$  개의 변수를 가지는 데이터를 다중회귀 모델에 적용하는 방법
- PCA를 통해 생성한 데이터는 공분산이 존재하지 않으므로, 다중공선성에 따른 선형회귀모델의 문제점을 방지할 수 있음

# PCA 응용 - Principal Component Regression (PCR)

다중회귀모델

다중회귀모델 회귀계수

$$Y = X\beta + \varepsilon$$

$X$  : 기존 데이터

주성분 회귀모델

주성분 회귀모델 회귀계수

$$Y = Zq + e$$

$Z$  : 주성분 데이터 (PCA score)

# PCA 응용 - Principal Component Regression (PCR)

**Step 1.** 데이터 정규화 (mean centering)

**Step 2.** Covariance (correlation) matrix 및 eigenvalue, eigenvector를 계산하여 PCA 수행

$$Z_1 = e(1)\mathbf{X} = e_{11} \cdot X_1 + e_{12} \cdot X_2 + \dots + e_{15} \cdot X_5$$

$$Z_2 = e(2)\mathbf{X} = e_{21} \cdot X_1 + e_{22} \cdot X_2 + \dots + e_{25} \cdot X_5$$

...

...

$$Z_k = e(k)\mathbf{X} = e_{k1} \cdot X_1 + e_{k2} \cdot X_2 + \dots + e_{k5} \cdot X_5$$

**Step 3.** 추출된 데이터를 사용하여 회귀분석 진행

$$\hat{q} = (Z^T Z)^{-1} Z^T Y \quad \hat{Y} = Z \hat{q} = E_k^T X \hat{q}$$

# 주성분 분석 강의 자료 개요

---

- 주성분 분석 개요
- 주성분 분석 수리적 배경
- 주성분 분석 알고리즘
- 주성분 분석 예제

---

EOD